

多変量解析

第 3 回: 回帰分析 (2) 最尤法

藤本 衡

2018 年 4 月 25 日

本日の内容

- 最小 2 乗パラメータの性質
- より一般的な推定方法：最尤法
- 最尤法と最小 2 乗法の関係

最小 2 乗法の解 (再掲)

$$\beta^* = \frac{s_{xy}}{s_x}, \quad \alpha^* = \bar{y} - \frac{s_{xy}}{s_x} \bar{x} \quad (1)$$

$$\text{ただし} \left\{ \begin{array}{l} s_x = \frac{1}{n} \sum (x_i - \bar{x}) = \frac{1}{n} \sum x_i - \bar{x} \\ \quad (x \text{ の分散}) \\ s_{xy} = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y} \\ \quad (x \text{ と } y \text{ の共分散}) \end{array} \right.$$

最小 2 乗法の解の性質

- 最小 2 乗法の解 = 最小 2 乗推定量
- 推定量の性質って何があったっけ？
 - 一致推定量 (consistent estimator)
 - 不偏推定量 (unbiased estimator)
 - 有効推定量 (efficient estimator)
 - 最尤推定量 (maximum likelihood estimator)
 - etc.

一様性と不偏性

一様性 (consistency)

$$\forall \delta > 0, \lim_{n \rightarrow \infty} \mathbb{P}(|\beta^* - \beta| < \delta) = 1 \quad (\text{確率収束})$$

が成り立つとき β^* は一致推定量であるという

不偏性 (unbiasedness)

$$\mathbb{E}[\beta^*] = \beta$$

が成り立つとき β^* は不偏推定量であるという

α^*, β^* の分布

$$\beta^* = \frac{s_{xy}}{s_x} = \sum_{i=1}^n \frac{x_i - \bar{x}}{ns_x} y_i = \sum_{i=1}^n B_i y_i$$

$$\alpha^* = \bar{y} - \frac{s_{xy}}{s_x} \bar{x} = \sum_{i=1}^n \left\{ \frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{ns_x} \right\} y_i = \sum_{i=1}^n A_i y_i$$

$$\sum B_i = 0, \quad \sum B_i x_i = 1, \quad \sum B_i^2 = \frac{1}{ns_x}$$

$$\sum A_i = \boxed{\text{計算して!}}, \quad \sum A_i x_i = \boxed{\text{計算して!}}, \quad \sum A_i^2 = \boxed{\text{計算して!}}$$

α^*, β^* の分布 (2)

y_i を回帰モデルによって置き換えると

$$\beta^* = \sum_{i=1}^n B_i(\alpha + \beta x_i + \varepsilon_i) = \beta + \sum_{i=1}^n B_i \varepsilon_i$$

$$\alpha^* = \sum_{i=1}^n A_i(\alpha + \beta x_i + \varepsilon_i) = \alpha + \sum_{i=1}^n A_i \varepsilon_i$$

期待値の線形性より、 $\mathbb{E}[\varepsilon_i] = 0$ ならば以下が成り立つ

$$\mathbb{E}[\beta^*] = \beta, \quad \mathbb{E}[\alpha^*] = \alpha \quad (\text{不偏性の証明})$$

$\varepsilon \sim N(0, \sigma^2)$ (正規分布に従う) と仮定すると、

α^*, β^* はともに正規分布に従う

α^*, β^* の分布 (3)

残差の分散が一定であり ($\mathbb{V}[\varepsilon_i] = \sigma^2$) かつ残差が無相関であるという仮定が成り立つとき、

$$\mathbb{V}[\beta^*] = \mathbb{V}[\varepsilon] \sum_i B_i^2 = \frac{\sigma^2}{n s_x}$$

$$\mathbb{V}[\alpha^*] = \mathbb{V}[\varepsilon] \sum_i A_i^2 = \sigma^2 \left\{ \frac{1}{n} + \frac{\bar{x}^2}{n s_x} \right\}$$

ともに $n \rightarrow \infty$ で 0 に収束するので、チェビシェフの不等式より

$$\beta^* \xrightarrow{p} \beta, \quad \alpha^* \xrightarrow{p} \alpha \quad (\text{一致性の証明})$$

BLUE (Best Linear Unbiased Estimator)

- 有効推定量: 不偏推定量のうち分散最小のもの
- 線形推定量: 確率変数 (ε_i) の線形関数として与えられる推定量
- 最小 2 乗推定量は線形不偏推定量の中で分散最小である (有効推定量)
⇒ 最良線形不偏推定量 (BLUE)
- (証明は面倒なので省略)

y_i の条件付き密度関数

$\varepsilon_i \sim N(0, \sigma^2)$ (正規分布に従う) と仮定すると、
 x_1, \dots, x_n が与えられたときの y_1, \dots, y_n の条件付き同時密度関数は

$$\begin{aligned} & f(y_1, \dots, y_n | x_1, \dots, x_n; \sigma^2, \alpha, \beta) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2} \left(\frac{\varepsilon_i}{\sigma} \right)^2 \right\} \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \alpha - \beta x_i)^2 \right\} \end{aligned}$$

最尤推定法 (maximum likelihood estimation: MSE)

y_i の条件付き同時密度関数は、未知パラメータ σ^2, α, β の関数と解釈することもできる

$$\begin{aligned} L(\sigma^2, \alpha, \beta | y_1, \dots, y_n, x_1, \dots, x_n) \\ = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \alpha - \beta x_i)^2 \right\} \end{aligned}$$

- 与えられたデータで尤度関数を最大にするような σ^2, α, β を求めよう
⇒ 最尤推定法

対数尤度関数 (log-likelihood function)

- 尤度関数が積表現 微分がめんどい
- 対数をとっても極大点は変わらない
- 最尤法では対数尤度関数を使うことが多い

対数尤度関数

$$\log L(\sigma^2, \alpha, \beta | y_1, \dots, y_n, x_1, \dots, x_n) = \text{計算してみて!}$$

最尤法と最小 2 乗法

- 尤度関数の最大化 \iff 残差平方和の最小化
- あれ？最小 2 乗法と同じ？
- そうです、残差が正規分布に従う場合は最小 2 乗法は最尤推定をしていることになります
- 残差の分布が正規分布でない場合は結果は異なる
 - 最尤法はより一般的（広く適用できる）と言える