

# 多变量解析

## 第 4 回: 回帰分析 (3) 重回帰分析

藤本 衡

2018 年 5 月 2 日

# 本日の内容

- 2 以上の説明変数を扱う—重回帰分析
- 重回帰分析の定式化: ベクトル・行列表現
- 重回帰係数の解を求める

# $N$ 個の説明変数がある回帰モデル

$$\begin{aligned} Y &= \alpha + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_N X_N + \varepsilon \\ &= \alpha + \sum_{j=1}^N \beta_j X_j + \varepsilon \end{aligned} \tag{1}$$

# $n$ 個体からデータが得られたとき

$(x_{i1}, x_{i2}, \dots, x_{iN}, y_i)$ : 個体  $i$  から得られる観測値

$\varepsilon_i$ : 個体  $i$  に関する観測誤差

$$y_1 = \alpha + \beta_1 x_{11} + \beta_2 x_{12} + \cdots + \beta_N x_{1N} + \varepsilon_1$$

$$y_2 = \alpha + \beta_1 x_{21} + \beta_2 x_{22} + \cdots + \beta_N x_{2N} + \varepsilon_2$$

$\vdots$

$$y_n = \alpha + \beta_1 x_{n1} + \beta_2 x_{n2} + \cdots + \beta_N x_{nN} + \varepsilon_n$$

ベクトル・行列を使って表現できそうな？

# 残差平方和の最小化

$$RSS = \sum_{i=1}^n \left( y_i - \alpha - \sum_{j=1}^N \beta_j x_{ij} \right)^2 \quad (2)$$

は  $\alpha$ ,  $\beta$  の凸 2 次関数である。 $\frac{\partial RSS}{\partial \alpha} = 0$  を満たす  $\alpha$  は

$$\alpha = \frac{1}{n} \sum_{i=1}^n \left( y_i - \sum_{j=1}^N \beta_j x_{ij} \right) = \bar{y} - \sum_{j=1}^N \beta_j \bar{x}_j \quad (3)$$

(3) を (2) に代入すると、

$$RSS = \sum_{i=1}^n \left\{ (y_i - \bar{y}) - \sum_{j=1}^N \beta_j (x_{ij} - \bar{x}_j) \right\}^2 \quad (4)$$

# 残差平方和の最小化 (2)

$v_i = y_i - \bar{y}$ ,  $\chi_{ij} = x_{ij} - \bar{x}_j$  とおき、以下のように記号を定義する。

$$\mathbf{X} = \begin{pmatrix} \chi_{11} & \chi_{12} & \cdots & \chi_{1N} \\ \chi_{21} & \chi_{22} & \cdots & \chi_{2N} \\ \vdots & \vdots & & \vdots \\ \chi_{n1} & \chi_{n2} & \cdots & \chi_{nN} \end{pmatrix}, \quad \mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_N \end{pmatrix}$$

このとき

$$\text{RSS} = (\mathbf{v} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{v} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{v}^\top \mathbf{v} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{v} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} \quad (5)$$

# 残差平方和の最小化 (3)

(5) 式を  $\beta$  について偏微分し極小点を求めると、

$$\frac{\partial \text{RSS}}{\partial \beta} = -2X^T v + 2X^T X \beta = 0$$

すなわち、以下の一次方程式を満たす  $\beta$  が、求める解である。

$$X^T X \beta = X^T v$$

$\frac{1}{n} X^T X = C$ ,  $\frac{1}{n} X^T v = c_y$  とおくと以下のように書き換えられる。

$$C \beta = c_y \tag{6}$$

よって、(6) 式の解  $\beta^*$  は次式で得られる。

$$\beta^* = C^{-1} c_y \tag{7}$$

# 分散共分散行列 (covariance matrix)

$C$  の  $(k, \ell)$  要素は  $X_k$  と  $X_\ell$  の共分散を与える  
( $k = \ell$  のときは  $X_k$  の分散)。  $C$  を分散共分散行列と呼ぶ。  
 $C$  は実対称行列である点に注意。

$$\frac{1}{n} \sum_{i=1}^n \chi_{ik} \chi_{i\ell} = \frac{1}{n} \sum_{i=1}^n (x_{ik} - \bar{x}_k)(x_{i\ell} - \bar{x}_\ell) = s_{k,\ell}$$

同様に、 $c_y$  の第  $k$  要素は  $x_k$  と  $y$  の共分散を与える。

$$\frac{1}{n} \sum_{i=1}^n \chi_{ik} v_k = \frac{1}{n} \sum_{i=1}^n (x_{ik} - \bar{x}_k)(y_k - \bar{y}) = s_{k,y}$$



# 方程式の解法

- (7) 式は逆行列の計算が必要になる
- $C$  が小さければ大したことはないが、大きいと大変
- 対称行列（エルミート行列）を用いた方程式の例は多い
- 解法もいろいろ提案されている（主に行列分解を用いた方法）

## 例: LU 分解

$C$  を下三角行列  $L$  と上三角行列  $U$  に分解する ( $C = LU$ )  
 $\gamma = U\beta$  とおくと、(6) 式は以下の 2 つの方程式と等価であり、それらは単なる代入の繰り返しで解を得ることができる。

$$L\gamma = c_y, \quad U\beta = \gamma$$

# LU 分解の求め方

$C$  の対角・右上三角成分は  $U$  の、左下三角成分は  $L$  の非零成分になる。  
なお、 $L$  の対角成分は 1 とする (Doolittle 法)

```
for (k = 0; k < m; k++) {  
    for (i = k + 1; i < m; i++) {  
        C[i][k] /= C[k][k];  
        for (j = k + 1; j < m; j++) {  
            C[i][j] -= C[i][k] * C[k][j];  
        }  
    }  
}
```

$C$  の対角成分  $C[k][k]$  が非零でなければならない点に注意。

# QR 分解

$C$  を直交行列  $Q$  と上三角行列  $R$  に分解する ( $C = QR$ )

$$QR\beta = c_y \longrightarrow R\beta = Q^{-1}c_y$$

$Q^{-1} = Q^T$  であり (直交行列の定義)  $R$  は上三角行列なので LU 分解と同様に代入によって  $\beta$  の解が得られる。

$Q$ ,  $R$  を得るにはハウスホルダー変換やグラム・シュミット分解などを用いる。

# 重回帰分析小テスト

以下のデータが与えられたときに、最小二乗法により  $\alpha$ ,  $\beta_1$ ,  $\beta_2$  を求めよ。

日	最高気温 $y$	最低気温 $x_1$	日照時間 $x_2$
1	11.4	-2.0	9.5
2	7.6	-0.8	9.1
3	7.5	-2.4	8.2
4	9.0	-3.1	9.8
5	11.5	-0.7	9.8