

# 多変量解析

## 第 6 回: 主成分分析 (2) 解析手法

藤本 衡

2018 年 5 月 16 日

# 本日の内容

- 主成分分析 ( $N$  変量) の解法
- 寄与率
- 主成分得点
- 負荷量

## 2 変量の解法

$$\begin{pmatrix} \mathbb{V}[X_1] & \text{Cov}[X_1, X_2] \\ \text{Cov}[X_1, X_2] & \mathbb{V}[X_2] \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \lambda \begin{pmatrix} w_1 \\ w_2 \end{pmatrix}$$

つまり

$$Cw = \lambda w$$

の形の固有値問題を解けばよい。 $C$  は  $X_1, X_2$  の分散共分散行列であり、 $\lambda$  は  $C$  の固有値、 $w$  は対応する右固有ベクトル。

# $N$ 変量の主成分分析

- やることは同じ（行列が 2 次でなく  $N$  次になるだけ）

$$\begin{pmatrix} \mathbb{V}[X_1] & \text{Cov}[X_1, X_2] & \cdots & \text{Cov}[X_1, X_N] \\ \text{Cov}[X_2, X_1] & \mathbb{V}[X_2] & \cdots & \text{Cov}[X_2, X_N] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[X_N, X_1] & \text{Cov}[X_N, X_2] & \cdots & \mathbb{V}[X_N] \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{pmatrix} = \lambda \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{pmatrix}$$

# $N$ 次正方行列の固有値

- $N$  次の固有方程式の解を求める？
  - 2 次なら簡単、3 次もなんとか、4 次は？（できます）
  - 5 次以上は代数的に解を求めるための一般的な方法がない（できない）
- 代数的に無理なら数値計算で求めよう
  - べき乗法（最大固有値のみ）
  - QR 法

# べき乗法 (power method)

- 絶対値最大の固有値が重解だと適用できない

## べき乗法のアルゴリズム

- 1  $\|w^{(0)}\|_2 = 1$  なる初期ベクトル  $w^{(0)}$  を定める.  $i = 1$ .
- 2  $v^{(i)} \leftarrow Cw^{(i-1)}, \lambda^{(i)} \leftarrow w^{(i-1)\top} v^{(i)}, w^{(i)} \leftarrow \frac{v^{(i)}}{\|v^{(i)}\|_2}$
- 3  $\forall j, \left| \frac{w_j^{(i)}}{w_j^{(i-1)}} \right| < \varepsilon ? \rightarrow$  真ならば収束, さもなくば 2 へ戻る
- 4  $\lambda^{(i)}, w^{(i)}$  が絶対値最大固有値  $\lambda_1$  と対応する右固有ベクトル  $w_1$  を与える

# ヴィーラント減次 (Wielandt deflation)

- べき乗法は絶対値最大の固有値しか得られない？
- 対称行列であれば下記の方法で他の固有値も得られる
  - 非対称でも少し形を変えるとなんとかなる

## ヴィーラント減次による $\lambda_j$ の導出

- ①  $C_1 = C$  とおく.  $j = 1$ .
- ②  $C_j$  の絶対値最大固有値  $\lambda_j$  と対応する右固有ベクトル  $w_j$  を求める.
- ③  $j < N$  ならば  $C_{j+1} = C_j - \lambda_j w_j w_j^T$ ,  $j \leftarrow j + 1$  として 2 に戻る.

# QR 法

- 三角行列の対角成分が固有値になることを利用
- QR 分解を繰り返して、三角行列に収束させる
- 固有ベクトルを求めるには別途計算が必要

## QR 法のアルゴリズム

- ①  $C_1 = C, i = 1.$
- ②  $C_i \rightarrow Q_i R_i$
- ③  $C_{i+1} \leftarrow R_i Q_i = Q_i^T C_i Q_i$
- ④  $C_{i+1}$  の下三角成分が十分小さくなれば収束, さもなくば  $i \leftarrow i + 1$  として 2 へ戻る



# 寄与率 (contribution)

- 主成分はどの程度データのばらつきを表現できているか？
- 第 2, 3, ... 主成分を求める必要があるのか？
- $\lambda$  は主成分の分散に比例している
  - 実際、データを標準化し相関行列で求めた場合、 $\lambda = \mathbb{V}[Z]$  である

## 寄与率

第  $j$  主成分の寄与率  $r_j$  は以下の式で与えられる

$$r_j = \frac{\lambda_j}{\sum_{k=1}^N \lambda_k} = \frac{\lambda_j}{\sum_{k=1}^N \mathbb{V}[X_k]}$$

# 寄与率と求めるべき主成分の数

- 第  $j$  主成分までの累積寄与率は  $\sum_{k=1}^j r_k$  で与えられる
- 求めるべき主成分の基準は必ずしも明確ではない
- 累積寄与率 80% ~ 90%あたりがひとつの目安
- または第  $r_j$  に対して  $r_{j+1}$  が大きく減少しているあたりで打ち止め

# 主成分得点

- 各個体ごとに、主成分の式にデータを代入したもの

## 主成分得点 (主成分スコア)

第  $j$  主成分

$$Z_j = w_{j1}X_1 + w_{j2}X_2 + \cdots w_{jN}X_N$$

に対して、各個体の主成分得点は以下のように得られる。

$$z_{j1} = w_{j1}x_{11} + w_{j2}x_{12} + \cdots w_{jN}x_{1N}$$

$$z_{j2} = w_{j1}x_{21} + w_{j2}x_{22} + \cdots w_{jN}x_{2N}$$

$\vdots$

$$z_{jn} = w_{j1}x_{n1} + w_{j2}x_{n2} + \cdots w_{jN}x_{nN}$$

# 例: 数学と国語

- 不偏分散・不偏共分散を用い標準化しない場合

- $\lambda_1 = 284.7, w_{11} = 0.8718, w_{12} = -0.4899, r_1 = 0.92$
- $\lambda_2 = 24.15, w_{21} = -0.4899, w_{22} = 0.8718, r_2 = 0.08$

学生	数学 ( $x_{i1}$ )	国語 ( $x_{i2}$ )	第 1 主成分得点 ( $w_{11}x_{i1} + w_{12}x_{i2}$ )	第 2 主成分得点 ( $w_{21}x_{i1} + w_{22}x_{i2}$ )
A	88	65	44.87	-13.55
B	62	77	16.33	-36.75
C	90	52	52.98	-1.24
D	57	70	15.40	-33.10
E	72	70	28.47	-25.75

# 負荷量 (loading)

- 変量  $X_k$  と  $Z_j$  の相関係数は、 $X_k$  が主成分に与える影響の大きさとその方向を示す


## 主成分負荷量 (因子負荷量)

$X_k$  と  $Z_j$  の相関係数は以下の式で与えられる

$$\frac{\sqrt{\lambda_j} w_{jk}}{\sqrt{\mathbb{V}[X_k]}}$$


これを  $X_k$  の主成分負荷量と呼ぶ。(因子分析とも関係するため、因子負荷量と呼ばれることもある)

# 主成分得点と負荷量の散布図



- 主成分得点で個体をプロット
- 主成分負荷量で変量をプロット
- 傾向や影響を読み取る

# 主成分得点と負荷量の散布図 (5 科目版)



- $r_1 = 0.74$ ,  $r_2 = 0.16$
- 何か読み取れるでしょうか？